

RESEARCH ARTICLE

基于多层感知机的多层介质薄膜光谱预测与辅助设计

MLP-Based Spectral Prediction and Data-Driven Design of Multilayer Dielectric Thin Films

姓名：__李翔__ 学号：__2023270034__

 λ_{target} : __480__ nm seed: __270034__ design_seed: __270035__

Abstract

【写作提示】150–250 字，依次说明研究问题、TMM 数据生成、MLP 代理模型、主要结果和结论。

多层介质薄膜的设计需要反复计算光谱，而每一次结构试算通常都要走一遍传输矩阵法（TMM），穷举筛选代价很高。本文把这个问题做成一个小型“科学智能”流程：用 TMM 为 Air/H/L/H/L/Glass 膜系（ $n_H=2.30$, $n_L=1.45$, $n_s=1.52$ ）生成 5000 组“膜厚—反射率”数据，再训练一个 4-128-128-64-41 的多层感知机（MLP），把四层膜厚（40–180 nm）映射到 400–800 nm 内 41 个波长点的反射率。在留出测试集上，网络预测的 RMSE 为 0.0060；随着训练样本从 500 增加到 4000，误差单调下降（0.026→0.006）且边际收益递减。使用独立的 design_seed，MLP 可在毫秒级筛选 10000 个新候选，再经精确 TMM 复核，得到 480 nm 处反射率仅 0.0003 的减反设计。MLP 是准确而廉价的代理模型，TMM 仍是最终的物理校验。

Keywords: optical thin films; transfer matrix method; multilayer perceptron; surrogate model; AI for Science

1. Introduction

【写作提示】建议 3–4 段：研究背景→TMM 等物理计算方法→AI 代理模型的意义→本文研究目标。不要写成综述。

多层介质薄膜由若干层透明薄层堆叠而成，其光谱响应来自各界面反射光之间的干涉，由层数、每层材料折射率和物理厚度共同决定，因此是设计变量的高度非线性函数。这类膜系广泛用作增透膜、高反膜、带通滤光片和辐射制冷涂层。

在材料固定的前提下，由膜厚正算反射谱是经典问题，可由传输矩阵法精确求解——它用一个 2×2 特征矩阵逐层推导电场与磁场。单次 TMM 很快，但即便只有四层，连续膜厚空间的搜索仍需要成千上万次重复计算，而“由目标光谱反求膜厚”的逆问题没有解析解。

机器学习提供了另一条路：用有限次 TMM 仿真训练一个代理模型，学习膜厚到光谱的非线性映射，之后预测新结构可以快几个数量级。把它用于粗筛大量候选，再只对少数最优结构做精确 TMM，就是典型的“物理+数据”科学智能流程。

本文把问题控制得小而可复现，回答三个问题：Q1，简单 MLP 能否从四个膜厚准确预测整条反射谱？Q2，训练数据增加时误差如何变化？Q3，MLP 能否作为代理快速筛选目标波长设计，其结果又如何与 TMM 对齐？




图 1 总体流程：TMM 正仿真 → 数据集 → MLP 代理模型 → 10000 候选快速筛选 → TMM 复核最优设计

2. Materials and Methods

【写作提示】Methods 应做到别人可以依据本节和 GitHub 仓库复现工作。所有参数以实际代码为准。

2.1 Optical model and transfer matrix method

膜系为 Air / H / L / H / L / Glass，共四层功能膜，正入射；忽略吸收与色散，正入射下 s、p 偏振简并。折射率取 $n_0=1.00$ （空气）、 $n_H=2.30$ 、 $n_L=1.45$ 、 $n_s=1.52$ （玻璃基底）。第 j 层相位厚度 $\delta_j = 2\pi \cdot n_j \cdot d_j / \lambda$ ，其特征矩阵为

$$M_j = \begin{bmatrix} \cos \delta_j & i \sin \delta_j / n_j \\ i n_j \sin \delta_j & \cos \delta_j \end{bmatrix}$$

总矩阵 $M = M_1 \cdot M_2 \cdot M_3 \cdot M_4$ 。记 $M = \begin{bmatrix} m_{11} & m_{12} \\ m_{21} & m_{22} \end{bmatrix}$ ，由基底导纳得 $B = m_{11} + m_{12} \cdot n_s$ ， $C = m_{21} + m_{22} \cdot n_s$ ；反射系数 $r = (B - C) / (B + C)$ （空气导纳取 1），反射率 $R = |r|^2$ 。代码用裸玻璃极限 $R = ((n_s - 1) / (n_s + 1))^2 \approx 0.0426$ 做了自检，结果一致。

【写作提示】补充实际代码中使用的 2×2 特征矩阵、矩阵连乘方式和反射率 R 的计算公式。




图 2. 物理模型：Air/H/L/H/L/Glass 四层膜系，正入射下的入射光 $I(\lambda)$ 与反射光 $R(\lambda)$

2.2 Student-specific target wavelength and random seed

学号后两位 $N = 34$ ，故 $\lambda_{\text{target}} = 450 + 10 \times (N \bmod 31) = 480 \text{ nm}$ 。主种子 $\text{seed} = 270034$ ，控制数据生成、固定划分和 MLP 初始化（random、numpy、torch 三处均设为 270034）。为避免训练数据与筛选候选重复，设计阶段使用 $\text{design_seed} = \text{seed} + 1 = 270035$ 。

【写作提示】正文中给出自己的 λ_{target} 、 seed 与 design_seed ；GitHub 代码中必须显式设置随机种子。

2.3 Dataset generation

以 $\text{seed} = 270034$ 在每层 $[40, 180] \text{ nm}$ 内均匀采样 5000 组膜厚向量，用 TMM 在 $400\text{--}800 \text{ nm}$ 、步长 10 nm （共 41 点）上计算反射率，再做一次固定随机排列，划分为 4000 训练 / 500 验证 / 500 测试。该划分在所有实验中保持不变。

2.4 MLP surrogate model

网络输入为标准化后的四个膜厚 $[d_1, d_2, d_3, d_4]$ ，输出为 41 个反射率，结构固定为 $4 \rightarrow 128 \rightarrow 128 \rightarrow 64 \rightarrow 41$ （隐藏层 ReLU，输出层线性）。输入用训练集均值方差标准化，反射率目标保持在 $[0, 1]$ 。损失为均方误差，Adam 优化（学习率 $1e-3$ ，batch 64），验证集 200 个 epoch 无改善则早停。

【写作提示】写清楚实际使用的激活函数、优化器、学习率、batch size、epoch，以及 seed 的设置方法。




图 3. MLP 结构：4 个膜厚输入 → 两个 128 单元隐藏层 → 64 单元层 → 41 个反射率输出

2.5 Training-size experiment

为研究 Q2，在固定训练池中依次取前 500、1000、2000、4000 个样本重训同一结构，验证集和测试集始终为固定的 500 个样本，其余优化设置保持不变。

2.6 MLP-assisted thin-film screening

用 `design_seed = 270035` 生成 10000 个未参与训练的新候选，训练好的 MLP 预测其光谱，按 $R(480\text{ nm})$ 升序排列（减反目标），取前 10 名用 TMM 精确重算，最后按 TMM 结果重新排序取 Top5。

3. Results

【写作提示】Results 重点报告客观结果和定量指标，原因分析主要放在 Discussion。

3.1 MLP training and spectral prediction

训练平滑收敛，约 2200 个 epoch 时早停，最佳验证 MSE 约 3.5×10^{-5} （图 4）。在留出的 500 个测试样本上， $\text{RMSE} = 0.0060$ ， $\text{MAE} = 0.0042$ 。代表性测试谱（图 5）显示，MLP 在大部分波段都能复现 TMM 参考谱的峰位和整体线型，只在尖锐极值附近有小偏差。




图 4. MLP 代理模型的训练与验证 MSE 损失（纵轴对数）




图 5. 三个代表性测试样本：TMM 参考（黑实线）与 MLP 预测（红虚线）对比；绿色点线为 480 nm

3.2 Effect of training-set size

测试 RMSE 从 500 样本的 0.0262，降到 1000 的 0.0135、2000 的 0.0097、4000 的 0.0060（图 6）。数据翻倍时误差先近似减半，但随着样本增多，增量收益不断缩小，呈现边际递减而非线性改善。




图 6. 训练集规模对测试 RMSE 的影响；验证集与测试集固定不变

3.3 MLP-assisted thin-film design

用 MLP 筛选 10000 个新候选，再对前 10 名做 TMM 复核，得到表 1。最优设计 $d = (84.2, 125.4, 63.5, 155.2)$ nm，TMM 复核的 $R(480\text{ nm})$ 仅 0.0003，即在目标波长实现了近乎完全的相消干涉（图 7）；该设计的 MLP 预测谱与 TMM 复核谱几乎重合




图 7. MLP 选出的最优设计：TMM 复核（黑）与 MLP 预测（红虚线）光谱，在 480 nm 处反射率降至 $R \approx 0$

排名	d1/nm	d2/nm	d3/nm	d4/nm	MLP R@480	TMM R@480
1	84.2	125.4	63.5	155.2	-0.0060	0.0003
2	85.5	120.4	67.1	40.7	-0.0096	0.0012
3	117.1	70.7	128.5	58.3	-0.0044	0.0013
4	122.4	56.5	128.9	87.0	-0.0061	0.0025
5	123.3	176.6	77.8	90.4	-0.0039	0.0045

表 1. MLP 筛选并经 TMM 复核的 Top5 减反设计 ($\lambda = 480 \text{ nm}$)

3.4 Representative failure case

误差最大的测试样本（单样本 $\text{MSE} \approx 8.6 \times 10^{-4}$ ，图 8）中，MLP 系统性地把两个反射率波峰估高，并略微移动了峰位。绝对误差不大，但正好暴露了代理模型的软肋：窄而高的峰被平滑回归“平均”得不够准




图 8. 代表性失败案例：MLP 高估并轻微位移了测试谱中的反射率峰

4. Discussion

【写作提示】建议围绕预测准确性、数据量效应、代理模型的设计价值、失败原因与局限展开。

Q1: MLP 以约 0.006 的 RMSE 预测 41 点光谱，相对于 0–1 的反射率范围已经很小，足以区分膜系设计的优劣。误差集中在峰位和曲线交叉处——那里膜厚变化引起的光谱变化最剧烈，符合平滑回归在窄特征附近“平均化”的特点。

Q2: 增加训练数据可靠地降低误差，但边际递减明显。500→1000 误差约减半，2000→4000 只带来有限改善。对这个四层问题，几千次 TMM 仿真就足以训练出可用的代理模型，再多数据收益递减。

Q3: 代理模型的价值在筛选。MLP 排序 10000 个候选只需毫秒级，而 TMM 逐条计算要慢得多；最终最优设计 $R(480 \text{ nm}) = 0.0003$ 。值得注意的是，MLP 偶尔会输出略负的反射率（如 -0.006），这是回归模型没有 [0,1] 约束导致的、物理上不可能的值——这正是最终候选必须用 TMM 重算并重排的原因。两者分工：MLP 负责广度，TMM 负责可信。

局限：本模型固定了材料、层数和正入射条件，只是 [40,180] nm 训练范围内的插值器，外推能力有限；网络本身没有物理约束，原始输出不能直接当作精确结果。后续可加入有界输出、考虑色散，或采用预测与优化更耦合的串联模型。第四段：结合 Figure 8 讨论模型失效的可能原因及本研究的局限。

5. Conclusions

【写作提示】100–150 字，直接回答三个研究问题，并至少给出一个定量结果。

一个紧凑的 MLP (4–128–128–64–41) 能准确学习四层介质膜的 TMM 膜厚—光谱映射，测试 $\text{RMSE} = 0.0060$ (Q1)。预测误差随训练数据增加而单调下降，但边际递减 (500 样本 0.026 → 4000 样本 0.006) (Q2)。作为

快速代理，MLP 筛选 10000 个候选，经 TMM 复核后在 480 nm 找到 $R = 0.0003$ 的减反设计（Q3）。整个“物理仿真—数据代理—物理校验”流程，构成了一个虽小但完整的科学智能设计闭环。

Data and Code Availability

数据集由本研究的 TMM 代码生成。全部源码、训练与筛选脚本、依赖文件及复现说明见 GitHub 仓库 (<https://github.com/GGbondlp/->)； $\lambda_{\text{target}} = 480 \text{ nm}$ ， $\text{seed} = 270034$ ， $\text{design_seed} = 270035$ 。

References

【写作提示】建议 8–12 篇真实文献；至少覆盖光学薄膜 TMM、机器学习代理模型或 AI 辅助设计，并采用统一的 *Research Article* 参考文献格式。

- [1] Ma, T.; Ma, M.; Guo, L.J. Optical multilayer thin film structure inverse design: From optimization to deep learning. *iScience* 2025, 28, 112222.
- [2] Macleod, H.A. *Thin-Film Optical Filters*, 5th ed.; CRC Press: Boca Raton, 2017.
- [3] Born, M.; Wolf, E. *Principles of Optics*, 7th ed.; Cambridge University Press: Cambridge, 1999.
- [4] Rumelhart, D.E.; Hinton, G.E.; Williams, R.J. Learning representations by back-propagating errors. *Nature* 1986, 323, 533–536.
- [5] Goodfellow, I.; Bengio, Y.; Courville, A. *Deep Learning*; MIT Press: Cambridge, 2016.
- [6] Paszke, A. et al. PyTorch: An imperative style, high-performance deep learning library. *Adv. Neural Inf. Process. Syst.* 2019, 32, 8024–8035.
- [7] Piegari, A.; Flory, F. (Eds.) *Optical Thin Films and Coatings: From Materials to Applications*; Woodhead Publishing: Cambridge, 2018.
- [8] Goldberg, D.E. *Genetic Algorithms in Search, Optimization, and Machine Learning*; Addison-Wesley: Reading, 1989.
- [9] Molesky, S. et al. Machine learning and nanophotonic design. *Nat. Photonics* 2018, 12, 659–670.

Suggestions

课程设计很合理，因材施教，祝王老师越来越好！